Dzień 2 - Curve fitting

Spis treści

Curve fitting																		-
Ćwiczenie:	 		 				 		 									ļ

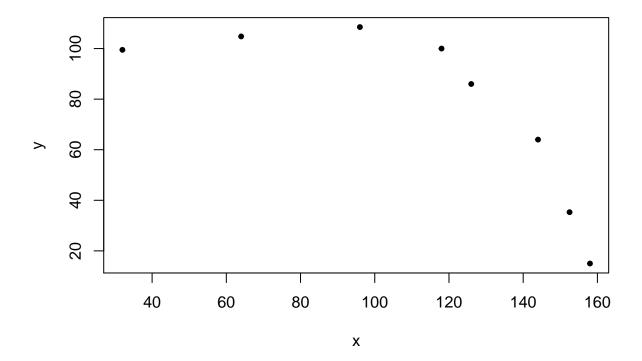
Curve fitting

Wersja pdf

"Curve fitting" (dopasowanie krzywej) to zadanie sprowadzająca się do szukania najbardziej dopasowanego modelu.

W przykładach ograniczymy się do jednej zmiennej objaśniającej, jednak można to w dosyć prosty sposób zastosować również przy kilku zmiennych objaśniających.

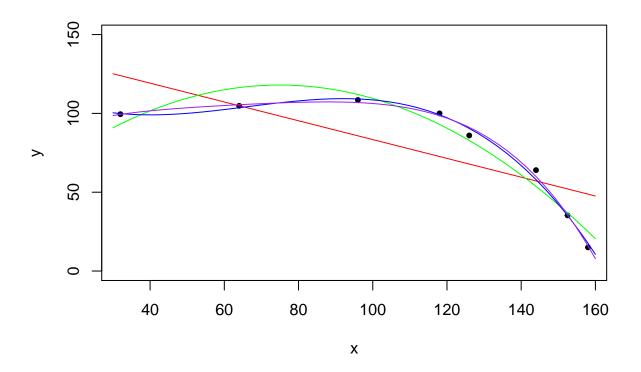
```
x <- c(32,64,96,118,126,144,152.5,158)
y <- c(99.5,104.8,108.5,100,86,64,35.3,15)
plot(x,y, pch=20)
```



Stwórzmy kilka modeli i zrób wykresy teoretycznych wartości z modelu:

```
model1 <- lm(y~x)
model2 <- lm(y~poly(x,2,raw=TRUE))
model3 <- lm(y~poly(x,3,raw=TRUE))</pre>
```

```
model4 <- lm(y~poly(x,4,raw=TRUE))
x.axis <- seq(30,160, length=50)
plot(x,y,pch=20,ylim=c(0,150))
lines(x.axis, predict(model1,data.frame(x=x.axis)), col="red")
lines(x.axis, predict(model2,data.frame(x=x.axis)), col="green")
lines(x.axis, predict(model3,data.frame(x=x.axis)), col="blue")
lines(x.axis, predict(model4,data.frame(x=x.axis)), col="purple")</pre>
```



```
## [1] 0.505235
summary(model2)$adj.r.squared
## [1] 0.9263129
summary(model3)$adj.r.squared
## [1] 0.9866455
summary(model4)$adj.r.squared
## [1] 0.9867671
Co nam pokaże anova?
anova(model1, model2, model4, model3)
## Analysis of Variance Table
##
## Model 1: y ~ x
## Model 2: y ~ poly(x, 2, raw = TRUE)
## Model 3: y \sim poly(x, 4, raw = TRUE)
## Model 4: y \sim poly(x, 3, raw = TRUE)
    Res.Df
               RSS Df Sum of Sq
                                             Pr(>F)
## 1
         6 3660.8
          5 454.3 1
                         3206.4 196.4919 0.0007862 ***
## 2
## 3
          3
             49.0 2
                          405.4 12.4212 0.0353688 *
## 4
          4 65.9 -1
                          -16.9 1.0368 0.3835381
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
Dodajmy model nieliniowy.
model5 < -nls(y \sim poly(x, 5, raw = TRUE)%*% coef, start = list(coef = c(a = 1, b = 2, c=2, d=4, e=2)))
anova(model4,model5)
## Warning in anova.lmlist(object, ...): models with response '"NULL"' removed
## because response differs from model 1
## Analysis of Variance Table
##
## Response: y
                          Df Sum Sq Mean Sq F value
                                                       Pr(>F)
## poly(x, 4, raw = TRUE) 4 8583.2 2145.81
                                               131.5 0.001064 **
                                      16.32
## Residuals
                           3
                               49.0
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
Musimy porównywać w większości wypadkóW modele "tego samego typu":
model6 < -nls(y \sim poly(x, 4, raw = TRUE) \% * \% coef, start = list(coef = c(a = 1, b = 2, c=2, d=1)))
anova(model6, model5)
## Analysis of Variance Table
##
## Model 1: y ~ poly(x, 4, raw = TRUE) %*% coef
## Model 2: y \sim poly(x, 5, raw = TRUE) %*% coef
   Res.Df Res.Sum Sq Df Sum Sq F value Pr(>F)
```

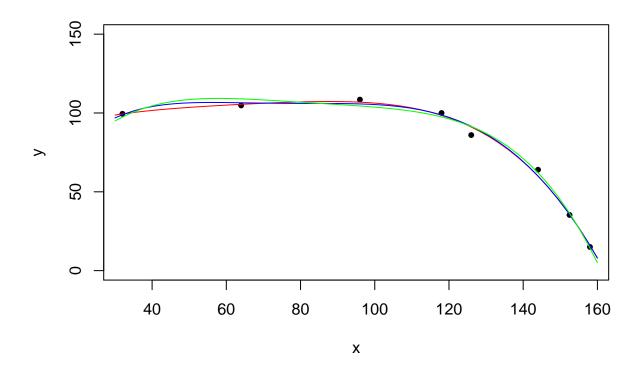
1

4

79.383

```
## 2
          3
                 60.188 1 19.195 0.9568 0.4001
Jak zatem porównywać? Pierwsza opcja to ręczne liczenie \mathbb{R}^2.
ym<-mean(y)
yh<-fitted(model4)</pre>
ssm < -sum((yh-ym)^2)
sst<-sum((y-ym)^2)
r2<-ssm/sst
r2
## [1] 0.9943288
yh<-fitted(model5)</pre>
ssm<-sum((yh-ym)^2)
sst<-sum((y-ym)^2)
r2<-ssm/sst
r2
## [1] 0.9946821
yh<-fitted(model6)</pre>
ssm<-sum((yh-ym)^2)</pre>
sst<-sum((y-ym)^2)
r2<-ssm/sst
r2
## [1] 0.998033
Zobaczmy wykresy.
plot(x,y,pch=20,ylim=c(0,150))
lines(x.axis, predict(model4,data.frame(x=x.axis)), col="red")
lines(x.axis, predict(model5,data.frame(x=x.axis)), col="blue")
```

lines(x.axis, predict(model6,data.frame(x=x.axis)), col="green")



Jak to mierzyć? Możemy sprawdzić tzw. kryterium informacyjne Akaikego (Akaike Information Criterion) - link.

AIC(model1) ## [1] 77.71092 AIC(model2) ## [1] 63.01831 AIC(model3) ## [1] 49.56936 AIC(model4) ## [1] 49.19471 AIC(model5) ## [1] 50.84723 AIC(model6)

Ćwiczenie:

[1] 51.06176

1. Wygenerujmy sobie dane:

```
x<-seq(10,50,1)
y<-100/x+rnorm(1,sd=2)
```

Poszukaj najlepszego modelu.