Dzień 2 - Tablica analizy wariancji - anova

Spis treści

ablica analizy wariancji - anova	1
Zmienne ciągłe	 1
Zmienne jakościowe objaśniające	 3
Porównywanie modeli	 5

Tablica analizy wariancji - anova

Wersja pdf

Zmienne ciągłe

```
Przeanalizuj kod w R:
```

```
library(tidyverse)
devtools::install_github("kassambara/datarium")
```

##

```
checking for file 'C:\Users\Piotrek\AppData\Local\Temp\RtmpMHMZhH\remotes2ef414dc4271\kassambara-dat
    checking for file 'C:\Users\Piotrek\AppData\Local\Temp\RtmpMHMZhH\remotes2ef414dc4271\kassambara-dat

v    checking for file 'C:\Users\Piotrek\AppData\Local\Temp\RtmpMHMZhH\remotes2ef414dc4271\kassambara-dat

##

-    preparing 'datarium':

##

checking DESCRIPTION meta-information ...
```

```
checking DESCRIPTION meta-information ...

checking DESCRIPTION meta-information ...

v checking DESCRIPTION meta-information
##
```

- checking for LF line-endings in source and make files and shell scripts (435ms) ##
- checking for empty or unneeded directories
 ##

```
looking to see if a 'data/datalist' file should be added
##
  building 'datarium_0.1.0.tar.gz'
##
##
data("marketing", package = "datarium")
model <- lm(sales ~ youtube + facebook + newspaper, data = marketing)
summary(model)
##
## Call:
## lm(formula = sales ~ youtube + facebook + newspaper, data = marketing)
##
## Residuals:
       Min
                      Median
##
                 1Q
                                   3Q
                                           Max
## -10.5932 -1.0690
                      0.2902
                               1.4272
                                        3.3951
##
## Coefficients:
               Estimate Std. Error t value Pr(>|t|)
##
## (Intercept) 3.526667
                          0.374290
                                    9.422
                                             <2e-16 ***
                          0.001395 32.809
## youtube
              0.045765
                                             <2e-16 ***
               0.188530
## facebook
                          0.008611 21.893
                                             <2e-16 ***
## newspaper
              -0.001037
                          0.005871 - 0.177
                                               0.86
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 2.023 on 196 degrees of freedom
## Multiple R-squared: 0.8972, Adjusted R-squared: 0.8956
## F-statistic: 570.3 on 3 and 196 DF, p-value: < 2.2e-16
anova(model)
## Analysis of Variance Table
## Response: sales
             Df Sum Sq Mean Sq
                                F value Pr(>F)
              1 4773.1 4773.1 1166.7308 <2e-16 ***
## youtube
## facebook
              1 2225.7
                        2225.7 544.0501 <2e-16 ***
                                  0.0312 0.8599
              1
## newspaper
                   0.1
                           0.1
## Residuals 196 801.8
                           4.1
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
```

Jak widać, ostatnia kolumna jest taka sama - nie otrzymujemy w przypadku zmiennych ciągłych nowych informacji.

Zmienne jakościowe objaśniające

Rozważmy przykład z danymi jakościowymi:

```
library(car)
data("Salaries")
head(Salaries)
##
         rank discipline yrs.since.phd yrs.service sex salary
## 1
         Prof
                       В
                                    19
                                                18 Male 139750
                                    20
## 2
         Prof
                       В
                                               16 Male 173200
## 3 AsstProf
                       В
                                    4
                                                3 Male 79750
## 4
                                    45
                                                39 Male 115000
         Prof
                       В
                                    40
## 5
         Prof
                       В
                                                41 Male 141500
## 6 AssocProf
                       В
                                     6
                                               6 Male 97000
model <- lm(salary ~ sex, data = Salaries)</pre>
summary(model)
##
## Call:
## lm(formula = salary ~ sex, data = Salaries)
## Residuals:
##
     Min
             1Q Median
                           3Q
                                 Max
## -57290 -23502 -6828 19710 116455
##
## Coefficients:
##
              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 101002
                         4809 21.001 < 2e-16 ***
## sexMale
                 14088
                             5065
                                   2.782 0.00567 **
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 30030 on 395 degrees of freedom
## Multiple R-squared: 0.01921,
                                   Adjusted R-squared: 0.01673
## F-statistic: 7.738 on 1 and 395 DF, p-value: 0.005667
anova (model)
## Analysis of Variance Table
## Response: salary
##
                    Sum Sq
                              Mean Sq F value
              1 6.9800e+09 6980014930 7.7377 0.005667 **
## sex
## Residuals 395 3.5632e+11 902077538
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
Jak to obliczamy?
y<-Salaries$salary
ssm<-sum((model$fitted.values - mean(y))^2)</pre>
```

[1] 6980014930

```
ssr<-sum((y-model\fitted.values)^2)</pre>
ssr
## [1] 356320627631
ssm/1
## [1] 6980014930
ssr/395
## [1] 902077538
f < -(ssm/1)/(ssr/395)
## [1] 7.737711
p<-1-pf(f, 1,395)
р
## [1] 0.005667107
Czemu nie wyszło to tak jak wcześniej? Wynika to z faktu, jak R intrepretuje zmienne jakościowe. Ostatni
level zmiennej sex to Male, więc ma przypisaną wartość 1, a potem (od końca) Female jako 0. Model liniowy
jest zapisano jako y = \beta_0 + \beta_1 x + \varepsilon. Wtedy \beta_0 + \beta_1 dotyczy Male, \beta_0 dotyczy Female. Samo \beta_1 dotyczy
różnicy między Male a Female.
Jeśli zmienna ma więcej niż 2 wartości cechy, to jest zamieniana na więcej zmiennych o dwóch wartościach
(levelach).
levels(Salaries$rank)
## [1] "AsstProf" "AssocProf" "Prof"
res <- model.matrix(~rank, data = Salaries)</pre>
head(res)
##
      (Intercept) rankAssocProf rankProf
## 1
                 1
                                 0
## 2
                 1
                                           1
## 3
                 1
                                 0
                                           0
## 4
                 1
                                 0
                                           1
## 5
                                 0
                                           1
                 1
## 6
                                           0
head(Salaries$rank)
## [1] Prof
                   Prof
                              AsstProf Prof
                                                     Prof
                                                                 AssocProf
## Levels: AsstProf AssocProf Prof
model2<-lm(salary ~ yrs.service + rank + discipline + sex, data = Salaries)</pre>
summary(model2)
##
## Call:
## lm(formula = salary ~ yrs.service + rank + discipline + sex,
##
        data = Salaries)
##
## Residuals:
##
      Min
                1Q Median
                                3Q
                                      Max
```

```
## -64202 -14255 -1533 10571 99163
##
## Coefficients:
                Estimate Std. Error t value Pr(>|t|)
##
## (Intercept)
                68351.67 4482.20 15.250 < 2e-16 ***
                  -88.78
                            111.64 -0.795 0.426958
## yrs.service
## rankAssocProf 14560.40
                            4098.32 3.553 0.000428 ***
## rankProf
                            3834.49 12.820 < 2e-16 ***
                49159.64
## disciplineB 13473.38
                            2315.50 5.819 1.24e-08 ***
## sexMale
                4771.25
                            3878.00 1.230 0.219311
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 22650 on 391 degrees of freedom
## Multiple R-squared: 0.4478, Adjusted R-squared: 0.4407
## F-statistic: 63.41 on 5 and 391 DF, p-value: < 2.2e-16
anova (model2)
## Analysis of Variance Table
## Response: salary
##
               Df
                      Sum Sq
                                Mean Sq F value
                                                   Pr(>F)
## yrs.service 1 4.0709e+10 4.0709e+10 79.3405 < 2.2e-16 ***
                2 1.0358e+11 5.1789e+10 100.9335 < 2.2e-16 ***
## discipline 1 1.7617e+10 1.7617e+10 34.3350 9.861e-09 ***
                1 7.7669e+08 7.7669e+08
## sex
                                         1.5137
                                                    0.2193
## Residuals
             391 2.0062e+11 5.1310e+08
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
Porównywanie modeli
fit <- lm(sr ~ ., data = LifeCycleSavings)</pre>
anova(fit)
## Analysis of Variance Table
##
## Response: sr
            Df Sum Sq Mean Sq F value
             1 204.12 204.118 14.1157 0.0004922 ***
## pop15
             1 53.34 53.343 3.6889 0.0611255
## pop75
             1 12.40 12.401 0.8576 0.3593551
## dpi
             1 63.05 63.054 4.3605 0.0424711 *
## Residuals 45 650.71 14.460
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## same effect via separate models
fit0 <- lm(sr ~ 1, data = LifeCycleSavings)
fit1 <- update(fit0, . ~ . + pop15)</pre>
fit2 <- update(fit1, . ~ . + pop75)</pre>
fit3 <- update(fit2, . ~ . + dpi)</pre>
fit4 <- update(fit3, . ~ . + ddpi)</pre>
anova(fit0, fit1, fit2, fit3, fit4, test = "F")
```

```
## Analysis of Variance Table
##
## Model 1: sr ~ 1
## Model 2: sr ~ pop15
## Model 3: sr ~ pop15 + pop75
## Model 4: sr ~ pop15 + pop75 + dpi
## Model 5: sr ~ pop15 + pop75 + dpi + ddpi
    Res.Df
              RSS Df Sum of Sq
                                F Pr(>F)
## 1
        49 983.63
## 2
        48 779.51 1
                       204.118 14.1157 0.0004922 ***
        47 726.17 1
                       53.343 3.6889 0.0611255 .
## 4
        46 713.77 1
                       12.401 0.8576 0.3593551
## 5
        45 650.71 1
                        63.054 4.3605 0.0424711 *
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
```

Jeśli otrzymane prawdopodobieństwo w ostatniej kolumnie jest mniejsze niż 0,05 to stwierdzamy, że bardziej zawiły model jest wystarczająco lepszy niż prostszy model. W przeciwnym wypadku wybieramy prostszy model.